Nomor 1 Batch Normalization - (Slide 6-8):

- Mekanisme statistik mini-batch: Batch Normalization menghitung mean dan variance dari satu mini-batch yang diambil acak, bukan dari seluruh dataset. Isi mini-batch berubah di setiap iterasi, jadi estimasi mean dan variance membawa noise stokastik. Noise ini mencegah model bergantung pada pola satu sampel dan mendorongnya mempelajari fitur yang lebih umum. Efeknya mirip regularisasi ringan pada Dropout.

- Kondisi instabilitas: Anggapan bahwa Batch Normalization bisa menggantikan Dropout gugur saat batch size terlalu kecil, misalnya di bawah 8. Estimasi mean dan varians dari sampel sesedikit itu meleset jauh dan berfluktuasi. Gradien ikut berubah-ubah dan pelatihan menjadi tidak stabil. Pada kondisi ini Dropout tetap berguna sebagai regularisasi tambahan.

Nomor 2 (Degradasi & Residual - Slide 10-12):

- Degradation problem muncul ketika plain CNN makin dalam. Ruang fungsi yang harus dipelajari makin kompleks, dan optimizer seperti Stochastic Gradient Descent (SGD) gagal menemukan parameter optimal. Padahal model dalam bisa meniru model dangkal lewat identity mapping.
- **Aliran gradien via skip connection:** Skip connection menulis output blok sebagai $H(x) = F(x) + x$. Saat backpropagation, chain rule memberikan $\frac{\partial H(x)}{\partial x} = \frac{\partial F(x)}{\partial x} + 1$.
- **Mitigasi vanishing gradient:** Konstanta "+1" membuka jalur langsung bagi gradien. Meski $\frac{\partial F(x)}{\partial x}$ mendekati nol di jaringan yang dalam, gradien total tidak lenyap karena suku 1 tetap ada. Sinyal error sampai ke lapisan awal.

Nomor 3 (Feature Extraction vs Fine-Tuning - Slide 14-16):

- **Jumlah trainable parameters:** Feature extraction membekukan bobot backbone dan hanya memperbarui head/classifier, jadi parameternya sedikit. Fine-tuning membuka seluruh atau sebagian backbone, jadi parameter yang diperbarui jauh lebih banyak.
- **Kebutuhan volume data:** Feature extraction cukup dengan data latih kecil. Fine-tuning butuh data latih besar agar tidak overfitting.
- **Beban komputasi dan memori per epoch:** Feature extraction lebih ringan karena backbone tidak menjalankan backward pass. Fine-tuning memakai lebih banyak VRAM dan waktu komputasi.

- **Risiko merusak representasi (destructive gradient updates):** Feature extraction tidak punya risiko ini karena lapisan bawaan terkunci. Fine-tuning dapat merusak bobot pre-trained yang sudah bagus bila learning rate terlalu tinggi di awal pelatihan.

Nomor 4 (Data Augmentation - Slide 20, 21, 23):

- **Pertimbangan metodologis (hanya pada train set):** Augmentasi memberi variasi sintetik selama pelatihan agar model tahan terhadap perubahan input dan tidak menghafal data. Validation dan test set mengukur performa model di dunia nyata. Augmentasi acak pada test set mengacaukan sinyal evaluasi: akurasi berubah-ubah antar-evaluasi dan tidak mencerminkan kemampuan model di kondisi riil.
- **Contoh transformasi yang tidak layak untuk pet breeds:** Color jittering ekstrem yang mengubah hue drastis, misalnya bulu menjadi hijau. Warna dan corak bulu adalah fitur semantik utama untuk membedakan ras, misalnya Golden Retriever dari Black Labrador. Transformasi ini menghapus ciri yang harus dipelajari model.

Nomor 5 (Catastrophic Forgetting - Slide 28-29):

Terjadinya fenomena: Catastrophic forgetting muncul saat model beradaptasi ke tugas baru lewat transfer learning dan menerima pembaruan gradien yang terlalu agresif. Pembaruan besar itu menimpa bobot fitur umum yang susah payah dipelajari pada tahap pre-training.

Strategi mitigasi:

- **Differential Learning Rate:** Beri LR kecil pada lapisan backbone awal dan LR lebih besar pada classifier di atas. Fitur level rendah seperti garis dan tepi tetap stabil, sementara lapisan atas cepat menyesuaikan diri dengan kelas baru.
- **Gradual Unfreezing:** Buka lapisan beku bertahap, mulai dari classifier paling atas turun ke lapisan bawah, tiap beberapa epoch. Lapisan yang baru diinisialisasi acak mengirim sinyal error besar, dan sinyal itu merusak bobot di bawahnya bila semua lapisan terbuka sekaligus. Dengan unfreezing bertahap, loss turun lebih dulu. Setelah itu representasi bawaan di-fine-tune pelan-pelan.