LAPORAN EKSPERIMEN TRANSFER LEARNING

Klasifikasi Citra Data Terbatas (Oxford-IIIT Pet Dataset)

Disusun oleh: Stephanie Halim (NIM: 2802502025)

1. Ringkasan Eksekutif & Pengaturan Eksperimen

Eksperimen ini menguji seberapa efektif transfer learning untuk klasifikasi hewan dengan data terbatas. Datanya berasal dari Oxford-IIIT Pet, dengan 10 kelas yang mencakup indeks 0-4 dan 12-16 dari urutan kelas bawaan torchvision. Pembagian data memakai stratified split dengan proporsi 70% latih, 15% validasi, dan 15% uji. Random seed 42 menjaga hasil tetap dapat direproduksi.

Log evaluasi menunjukkan set validasi berisi 149 citra, sehingga total dataset sekitar 1.000 citra. Angka ini cocok dengan sumber datanya, yaitu split trainval bawaan torchvision, yang memuat sekitar 100 citra per kelas. Baseline-nya ResNet-18 dengan batch 32, optimizer AdamW (weight decay 1e-2), dan fungsi kerugian Cross Entropy. Citra masuk pada resolusi 224×224 piksel dengan normalisasi standar ImageNet. Pelatihan berjalan maksimum 15 epoch. Early stopping menghentikannya bila validation loss tidak membaik selama 3 epoch berturut-turut (patience = 3).

2. Landasan Teori & Analisis Konseptual

2.1 Peran Regularisasi Batch Normalization

Batch Normalization (BN) menormalisasi aktivasi antar-lapisan dengan rata-rata dan varians dari tiap mini-batch selama pelatihan. Komposisi sampel berubah di setiap batch, sehingga statistik ini bergeser sedikit dan menyuntikkan noise ringan ke aktivasi. Noise tersebut meregularisasi model seperti Dropout dan menahan model agar tidak bergantung pada satu neuron.

Meski begitu, Dropout tidak selalu bisa dihapus saat model memakai BN. Pada batch size kecil, misalnya 2-8 sampel, estimasi statistik BN menjadi tidak stabil dan menyimpang jauh dari running statistics yang dipakai saat inferensi. Dropout yang diletakkan tepat sebelum lapisan BN juga dapat memicu variance shift: varians berbeda antara mode pelatihan dan inferensi, dan perbedaan itu bisa mengganggu kestabilan model.

2.2 Masalah Degradasi & Formulasi Residual

Secara teori, menambah kedalaman jaringan tidak akan menurunkan performa, sebab lapisan tambahan bisa mempelajari pemetaan identitas (identity mapping). Praktiknya berbeda. Pengoptimasi berbasis gradien kesulitan membuat tumpukan lapisan konvolusi non-linear mengonvergensi ke pemetaan $H(x) = x$. Plain CNN yang lebih dalam akhirnya mencatat error pelatihan lebih tinggi daripada yang dangkal. Gejala ini disebut masalah degradasi, dan overfitting bukan penyebabnya.

ResNet mengatasinya dengan blok residual $H(x) = F(x) + x$. Target pembelajaran bergeser ke fungsi residual $F(x) = H(x) - x$, sehingga jaringan cukup mendorong bobot $F(x)$ mendekati nol bila pemetaan identitas adalah solusi optimal. Pada backpropagation, turunan parsial terhadap masukan menghasilkan suku $(1 + \partial F/\partial x)$. Angka 1 membuka jalur langsung bagi gradien menuju lapisan awal, dan jalur itu mengurangi masalah vanishing gradient.

2.3 Feature Extraction vs. Fine-Tuning

Feature extraction dan fine-tuning berbeda pada cakupan bobot yang ikut diperbarui oleh gradien. Pada feature extraction (kondisi B2), seluruh backbone dibekukan dan hanya lapisan klasifikasi akhir (fc) yang dilatih, yaitu sekitar 5.130 parameter. Fine-tuning parsial pada layer4 + fc (kondisi B3) melatih ulang hingga 8.398.858 parameter.

Untuk data kecil, feature extraction lebih cocok: risiko overfitting rendah dan perhitungan gradiennya ringan. Fine-tuning menuntut kehati-hatian. Di awal pelatihan, bobot klasifikasi masih acak dan menghasilkan gradien besar yang mengalir ke backbone, sehingga dapat merusak fitur representasi yang sudah terbentuk (destructive gradient updates).

2.4 Prinsip Penerapan Augmentasi Data

Augmentasi data memperkaya variasi data latih supaya model belajar mengenali objek meski posisi atau pencahayaannya berubah. Pada evaluasi (set validasi dan uji), augmentasi acak harus dimatikan dan diganti transformasi deterministik: resize, center crop, dan normalisasi. Augmentasi acak saat evaluasi membuat estimasi performa tidak stabil dan hasilnya sulit direproduksi.

Jenis augmentasi juga harus sesuai dengan ciri yang membedakan kelas. Hue shift yang ekstrem tidak cocok untuk klasifikasi ras hewan, karena warna bulu menjadi petunjuk utama antar-ras. Eksperimen ini membatasi penyesuaian warna pada brightness dan kontras sebesar 0.2.

Dua koreksi di luar gaya: “transformasi stokastik deterministik” di naskah asli bertentangan dengan dirinya sendiri, jadi saya tulis “deterministik”. “Antar-spesies” saya ganti “antar-ras” karena kelas Oxford-IIIT Pet adalah ras, bukan spesies.

2.5 Mitigasi Catastrophic Forgetting

Catastrophic forgetting terjadi saat fine-tuning memakai learning rate terlalu tinggi dan menimpa fitur visual generik yang sudah dipelajari dari ImageNet. Eksperimen ini memakai dua strategi untuk mencegahnya:

- **Differential learning rate:** backbone pretrained memakai learning rate lebih kecil daripada classifier baru. Pada B3, layer4 memakai 1e-4 dan fc memakai 1e-3, sehingga bobot bawaan hanya bergeser sedikit.
- **Linear warmup:** learning rate naik bertahap di awal pelatihan. Langkah ini menahan lonjakan gradien selagi bobot classifier masih acak.

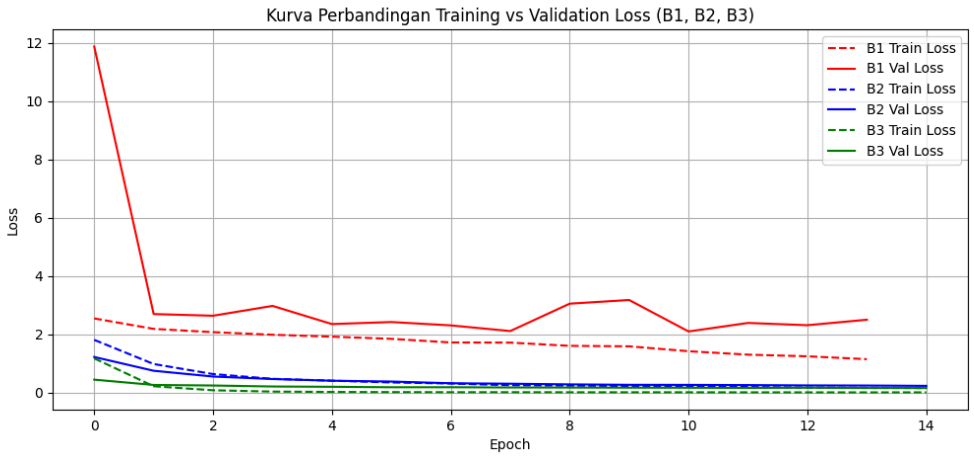
3. Hasil Eksperimen dan Komparasi Performa

3.1 Tabel Konsolidasi Performa Model (B1–B5)

Tabel 1. *Rangkuman kondisi B1–B5 (sumber: metrics_log.json).*

Kode	Strategi	Trainable params	Learning rate	Epoch	Waktu	Val acc	Macro F1 (test)
B1	*From scratch* (ResNet-18, inisialisasi acak)	11.181.642	1e-3 (seluruh parameter)	14	2.922,03	0,3087	0,3028
B2	*Feature extraction* (hanya fc)	5.130	1e-3 (fc)	15	1.341,91	0,9329	0,9202
B3	*Fine-tuning* layer4 + fc	8.398.858	1e-4 (layer4), 1e-3 (fc)	15	1.740,21	0,9530	0,9277
B4	B3 + augmentasi	8.398.858	1e-4 (layer4), 1e-3 (fc)	9	1.111,73	0,9463	0,9198
B5	EfficientNet-B0, *feature extraction*	12.810	1e-3 (classifier)	15	1.442,89	0,9262	0,9119

Catatan Hasil: Early stopping menghentikan model B1 dan B4 lebih awal, masing-masing pada epoch ke-11 dan ke-6. Model B2, B3, dan B5 berjalan penuh sampai batas 15 epoch. Macro F1 dihitung dari checkpoint dengan validation loss terendah pada tiap model.



Gambar 1. *Kurva training loss (putus-putus) dan validation loss (garis penuh) untuk B1, B2, dan B3.*

3.2 Analisis Komparatif Performa Model

Pelatihan dari nol (B1) vs. pretrained (B2 dan B3). B1 yang dilatih dari nol hanya mencapai akurasi validasi 30,87% dan Macro F1 0,3028. Sekitar 700 citra latih tidak cukup untuk melatih 11,2 juta parameter ResNet-18 tanpa bobot awal dari ImageNet.

Feature extraction (B2) vs. fine-tuning (B3). Fine-tuning parsial pada B3 menghasilkan performa terbaik, dengan akurasi validasi 95,30% dan Macro F1 0,9277. B3 mengalami overfitting ringan: training loss turun hingga 0,0031. B2 melatih parameter jauh lebih sedikit (5.130 vs. 8,39 juta) dalam waktu lebih singkat, dan tetap mencapai akurasi validasi 93,29%.

Pengaruh augmentasi (B4). Augmentasi mempersempit celah antara training loss dan validation loss. Pada epoch ke-9, B3 memiliki training loss 0,0068 dan validation loss 0,1679 (selisih 0,161), sedangkan B4 memiliki 0,0244 dan 0,1391 (selisih 0,115). Validation loss terbaik B4 juga lebih rendah (0,1369 vs. 0,1512), sehingga augmentasi meredam overfitting. Metrik akhirnya tidak ikut membaik: akurasi validasi 0,9463 vs. 0,9530 dan Macro F1 0,9198 vs. 0,9277. Selisih akurasi itu setara satu citra, jadi data ini belum cukup untuk menyimpulkan bahwa augmentasi merugikan. Augmentasi yang dipakai tergolong ringan (scale 0,8-1,0 dan rotasi 15°). Validation loss B4 yang naik turun kemungkinan memicu early stopping di epoch ke-9 (epoch terbaik ke-6), yang mungkin terlalu cepat. Waktu total B4 lebih singkat (1.111,73 vs. 1.740,21 detik) karena epoch-nya lebih sedikit. Per epoch, B4 justru lebih lama (123,5 vs. 116,0 detik), kemungkinan karena augmentasi berjalan di CPU.

EfficientNet-B0 (B5). Pada skenario feature extraction, EfficientNet-B0 mencapai Macro F1 0,9119 dan akurasi validasi 92,62%. Parameter trainable-nya hanya 12.810, tetapi dimensi fitur yang lebih besar (1.280) membuat waktu per epoch sedikit lebih lama daripada ResNet-18.

Dua catatan:

- Naskahmu memuat dua versi paragraf B4. Saya menggabungkannya dan membuang sudut pandang “saya” sesuai permintaanmu sebelumnya.
- Paragraf early stopping sebelumnya menyebut B4 berhenti di epoch ke-6, sedangkan teks ini menyebut epoch ke-9 dengan epoch terbaik ke-6. Dengan patience 3, versi epoch ke-9 yang konsisten, jadi angka “epoch ke-6” di paragraf lama kemungkinan perlu dikoreksi (B1 pada epoch ke-11 mungkin punya masalah serupa).

4. Failure Analysis & Rekomendasi Teknis

Evaluasi kualitatif dilakukan terhadap kesalahan prediktif model B3 pada set pengujian. Berdasarkan analisis sampel kesalahan, ditemukan beberapa pola dominan kekeliruan klasifikasi:



Gambar 2. *Enam sampel salah prediksi model B3 pada test set (label asli, prediksi, dan confidence).*

Model keliru pada beberapa kasus tertentu:

- **American Bulldog → Beagle (confidence 89,0%):** pola warna bulu (putih berbercak cokelat) dan telinga terlipat sama-sama mirip Beagle. Model mengabaikan struktur moncong dan bentuk kepala.
- **American Bulldog → German Shorthaired (confidence 22,2%):** objek berpose tidak biasa (menunduk) dan latar berupa vegetasi bunga yang dominan mengalihkan model.
- **English Setter → Beagle (confidence 69,4%):** cropping memotong area tubuh sehingga tekstur bulu khas hilang, dan cahaya dari belakang (backlight) memperburuknya.
- **Pencahayaan ekstrem:** foto yang sangat gelap, atau latar yang overexposed seperti salju, menghapus tekstur halus. Model lalu mengandalkan warna latar atau warna dasar bulu.
- **Ras yang mirip secara visual:** model tertukar antara Cocker Spaniel dan English Setter, juga antara Beagle dan Basset Hound. Ini tantangan khas klasifikasi fine-grained pada ras dengan ciri visual yang banyak beririsan.

4.1 Rekomendasi Teknis & Batasan Penelitian

Rekomendasi praktis. Untuk klasifikasi citra dengan data terbatas, mulai dari feature extraction (B2) sebagai baseline karena cepat dan efisien. Bila akurasi perlu naik, pakai fine-tuning parsial (B3) dengan differential learning rate dan data augmentation (B4), lalu pantau validation loss lewat early stopping untuk menahan overfitting.

Batasan eksperimen. Eksperimen ini punya empat keterbatasan:

1. Evaluasi memakai satu random seed.
2. Set uji kecil, sekitar 150 sampel.
3. Beberapa model berhenti di batas 15 epoch sebelum konvergen sepenuhnya.
4. Analisis atribut perhatian visual, seperti Grad-CAM, belum dilakukan secara kuantitatif.

5. Pernyataan Penggunaan AI (AI Disclosure Statement)

Gemini menyusun draf awal sebagian laporan ini dari instruksi tugas. Penulis (Stephanie Halim) memeriksa draf itu, merevisinya, dan mencocokkan angka serta klaimnya dengan log eksperimen.